

FICHES PROJETS ÉTUDIANTS

12 projets pratiques — Équipes de 3 — 4 à 5 semaines

 4 projets Mines  3 projets Aéronautique  3 projets Hydrologie  2 projets Finance

ID	Domaine	Famille ML	Dataset
M1	 MINES	Régression	Mining Process Flotation Plant
M2	 MINES	Classification	MSHA Accident Injuries Dataset
M3	 MINES	Séries temporelles	Microsoft Azure Predictive Maintenance +...
M4	 MINES	Classification multiclasse	FORCE 2020 Machine Learning Contest
A1	 AÉRONAUTIQUE	Régression RUL	NASA CMAPSS Turbofan Engine Degradation ...
A2	 AÉRONAUTIQUE	Non supervisé	NGAFID Aviation Maintenance Dataset
A3	 AÉRONAUTIQUE	NLP	NASA ASRS — Aviation Safety Reporting Sy...
H1	 HYDROLOGIE	Régression temporelle	Caravan — Global Community Dataset for L...
H2	 HYDROLOGIE	Classification binaire	Water Potability Dataset
H3	 HYDROLOGIE	Clustering	Enquêtes MICS UNICEF / DHS Burkina Faso ...
F1	 FINANCE	Classification	African Credit Scoring Challenge
F2	 FINANCE	Classification	Credit Card Fraud Detection — ULB Machin...

Qualité du minerai en sortie de flottation

Régression · Séries temporelles · Feature engineering

Techniques : Régression

Équipe : 3 étudiants | 3-4 semaines

Contexte et problématique

Une usine de flottation de minerai de fer produit des données capteurs toutes les 20 secondes. Le taux d'impureté (silice) dans le concentré final n'est mesuré qu'une fois par heure en laboratoire — trop lentement pour corriger le procédé en temps réel.

Objectif du projet

Construire un modèle de régression capable de prédire en continu le pourcentage de silice (%SiO₂) dans le concentré de minerai de fer à partir des paramètres opérationnels de l'usine, et déployer un dashboard de supervision pour les ingénieurs de procédé.

Dataset

Nom	Mining Process Flotation Plant
Source	Kaggle
URL / Accès	kaggle.com/datasets/edumagalhaes/quality-prediction-in-a-mining-process
Détails	737 453 instances 24 variables données industrielles réelles Mars–Sept 2017 CSV propre
Variables clés	Débit minerai, pH de la pulpe, débits de réactifs (amidon, amine), débits d'air et niveaux dans les colonnes de flottation (×7), % Fe et SiO ₂ en entrée et en sortie

Techniques ML attendues

- Analyse exploratoire et corrélations (heatmap)
- Agrégation temporelle (20s → 1h)
- Régression : Random Forest, XGBoost, SVR
- Feature importance (permutation + SHAP)
- Validation temporelle (pas de fuite de données)

Déroulement recommandé

- Semaine 1 — EDA, nettoyage, agrégation temporelle
- Semaine 2 — Feature engineering, sélection de variables
- Semaine 3 — Modélisation, comparaison de modèles, SHAP
- Semaine 4 — Dashboard Streamlit, rapport, présentation

Livrables attendus

- Notebook Jupyter commenté + README GitHub
- Modèle entraîné et sauvegardé (joblib/pickle)
- Dashboard Streamlit : saisie paramètres → prédiction + alerte si SiO₂ > seuil
- Rapport de 10-15 pages (IMRAD)

- Présentation orale 15 min + 5 min Q&A

Critères d'évaluation

RMSE, MAE, R^2 | Qualité du dashboard | Interprétabilité SHAP | Qualité du rapport

Prédiction du risque d'accident minier

Classification · Explicabilité SHAP · Déséquilibre de classes

Techniques : Classification

Équipe : 3 étudiants | 3-4 semaines

Contexte et problématique

Les accidents miniers restent l'une des principales causes de mortalité dans l'industrie extractive. Disposer d'un modèle capable d'anticiper les incidents graves à partir des conditions opérationnelles permettrait d'orienter les efforts de prévention.

Objectif du projet

À partir de 25 ans d'historique d'accidents miniers américains, construire un classificateur du niveau de gravité d'un incident (bénin / sérieux / fatal) et identifier les facteurs de risque dominants via l'explicabilité.

Dataset

Nom	MSHA Accident Injuries Dataset
Source	Data.gov — Mine Safety and Health Administration
URL / Accès	arlweb.msha.gov/opengovernmentdata/ogimsha.asp
Détails	+600 000 incidents depuis 2000 Variables : type de mine, activité en cours, équipement impliqué, conditions, jours perdus, degré de gravité CSV téléchargeable directement
Variables clés	Type d'accident, localisation dans la mine, équipement impliqué, activité en cours, expérience du mineur, conditions environnementales, degré d'atteinte (cible)

Techniques ML attendues

- Classification multiclasse (XGBoost, Random Forest, Logistic Regression)
- Gestion du déséquilibre (SMOTE, class_weight)
- SHAP values pour l'explicabilité
- Matrice de confusion, F1-score, AUC-ROC

Déroulement recommandé

- Semaine 1 — EDA, encodage variables catégorielles, création de la cible
- Semaine 2 — Gestion déséquilibre, baseline model
- Semaine 3 — Optimisation, SHAP, analyse des erreurs
- Semaine 4 — Dashboard, rapport, présentation

Livrables attendus

- Pipeline ML complet commenté
- Dashboard HSE : top 10 facteurs de risque + profil de mine à haut risque
- Rapport + présentation

Critères d'évaluation

F1-macro, AUC-ROC | Pertinence des SHAP values | Qualité du dashboard HSE

Maintenance prédictive équipements lourds miniers

Séries temporelles · Classification · Estimation RUL

Techniques : Séries temporelles

Équipe : 3 étudiants | 3-4 semaines

Contexte et problématique

Les pannes non planifiées sur les équipements lourds (foreuses, camions-benne, concasseurs) représentent les coûts opérationnels les plus élevés dans une mine. La maintenance prédictive basée sur les capteurs permet de passer d'une maintenance réactive à une maintenance anticipée.

Objectif du projet

À partir de données de capteurs industriels (température, vibrations, pression), prédire les pannes avant qu'elles surviennent, estimer la Durée de Vie Résiduelle (RUL) des équipements, et déployer un système d'alertes automatiques.

Dataset

Nom	Microsoft Azure Predictive Maintenance + AI4I 2020
Source	Kaggle
URL / Accès	kaggle.com/datasets/arnabbiswas1/microsoft-azure-predictive-maintenance kaggle.com/datasets/stephanmatzka/predictive-maintenance-dataset-ai4i-2020
Détails	Azure PdM : 100 machines × 12 mois de capteurs, historique erreurs & pannes AI4I 2020 : 10 000 entrées, 5 types de pannes, features normalisées CSV propre
Variables clés	Température, vibrations, pression, vitesse rotation, compteur d'erreurs, type de panne (cible), RUL calculable

Techniques ML attendues

- Feature engineering temporel (rolling mean, lag features)
- Classification binaire panne/pas panne (Random Forest, XGBoost)
- Régression RUL
- Validation temporelle (train sur passé, test sur futur)

Déroulement recommandé

- Semaine 1 — Exploration données capteurs, création des features temporelles
- Semaine 2 — Modèle de classification panne/pas panne
- Semaine 3 — Régression RUL, optimisation seuil d'alerte
- Semaine 4 — Dashboard, rapport, présentation

Livrables attendus

- Pipeline ML complet (feature engineering → modèle → alertes)
- Dashboard de suivi par équipement avec probabilité de panne et RUL estimé
- Rapport + présentation

Critères d'évaluation

Précision, Rappel, F1 (panne) | Erreur RUL (MAE) | Utilité opérationnelle du dashboard

Classification lithologique à partir de well logs

Classification multiclasse · Données géophysiques · Visualisation

Techniques : Classification multiclasse

Équipe : 3 étudiants | 3-4 semaines

Contexte et problématique

L'interprétation des diagraphies de forage (well logs) est une tâche fondamentale en exploration minière et pétrolière. Elle est traditionnellement réalisée manuellement par des géologues expérimentés, rendant le processus lent, coûteux et subjectif.

Objectif du projet

Identifier automatiquement les types de roches (grès, calcaire, argile, marl, tuf) à partir de mesures de logs géophysiques (gamma-ray, résistivité, densité, porosité) et visualiser les résultats sous forme de log stratigraphique interactif.

Dataset

Nom	FORCE 2020 Machine Learning Contest
Source	GitHub
URL / Accès	github.com/brendonhall/FORCE-2020-Lithology github.com/bolgebrygg/Force-2020-Machine-Learning-competition
Détails	100+ puits Well logs multi-courbes (GR, RDEP, RHOB, NPHI, DTC...) 12 lithologies interprétées par des géologues CSV + LAS files Licence ouverte
Variables clés	GR (gamma-ray), RDEP (résistivité profonde), RHOB (densité), NPHI (porosité neutronique), DTC (sonic), PEF, et autres — cible : code lithologique

Techniques ML attendues

- Nettoyage et normalisation de données géophysiques
- Classification multiclasse (Random Forest, SVM, XGBoost, MLP)
- Gestion du déséquilibre inter-lithologies
- Validation croisée par puits (pas par lignes)

Déroutement recommandé

- Semaine 1 — Chargement LAS/CSV, visualisation des logs, EDA géologique
- Semaine 2 — Normalisation, encodage, baseline Random Forest
- Semaine 3 — Comparaison modèles, validation croisée par puits
- Semaine 4 — Visualisation log, rapport, présentation

Livrables attendus

- Modèle de classification + évaluation par puits
- Visualisation interactive : log réel vs log prédit côte à côte
- Rapport + présentation

Critères d'évaluation

F1-macro par lithologie | Validation cross-puits | Qualité de la visualisation log

Maintenance prédictive moteurs d'avion — Estimation de la durée de vie résiduelle

Régression RUL · Séries temporelles · Dégradation progressive

Techniques : Régression RUL

Équipe : 3 étudiants | 3-4 semaines

Contexte et problématique

Les moteurs turbofan sont des équipements critiques dont la défaillance en vol peut être catastrophique. La prédiction de la durée de vie résiduelle (RUL — Remaining Useful Life) à partir des données capteurs permet de planifier la maintenance avant la panne.

Objectif du projet

À partir de données capteurs de moteurs turbofan en dégradation progressive, construire un modèle de régression prédisant combien de cycles de vol restent avant la panne, et déployer un tableau de bord de suivi par moteur avec alertes de seuil critique.

Dataset

Nom	NASA CMAPSS Turbofan Engine Degradation Dataset
Source	Kaggle / NASA Ames
URL / Accès	kaggle.com/datasets/behrad3d/nasa-cmaps data.nasa.gov/dataset/Turbofan-engine-degradation-simulation-data-set
Détails	100 moteurs en entraînement 21 capteurs (température, pression, vitesse) 4 scénarios de dégradation (FD001 à FD004) Séries temporelles par cycles CSV propre
Variables clés	21 mesures capteurs par cycle (T2, T24, T30, T50, P2, P15, P30, Nf, Nc...) + paramètres opérationnels — cible : RUL (cycles restants)

Techniques ML attendues

- Calcul du RUL à partir des données brutes
- Feature engineering : rolling statistics, normalisation par moteur
- Régression : Random Forest, XGBoost, SVR
- Validation temporelle stricte

Déroutement recommandé

- Semaine 1 — Exploration données capteurs, calcul RUL, visualisation dégradation
- Semaine 2 — Feature engineering temporel, normalisation
- Semaine 3 — Modélisation, comparaison, optimisation
- Semaine 4 — Dashboard, rapport, présentation

Livrables attendus

- Pipeline RUL complet commenté
- Dashboard de suivi de flotte : RUL estimé par moteur + code couleur alerte
- Rapport + présentation

Critères d'évaluation

RMSE, MAE sur RUL | Score sur le test set NASA | Qualité du dashboard flotte

Détection d'anomalies sur données de vol réelles

Non supervisé · Isolation Forest · Séries temporelles multivariées

Techniques : Non supervisé	Équipe : 3 étudiants 3-4 semaines
----------------------------	-------------------------------------

Contexte et problématique

Des milliers d'heures de données de vol sont enregistrées chaque jour sur les aéronefs. Identifier manuellement les vols présentant des comportements anormaux précurseurs de pannes est impossible à grande échelle. L'apprentissage non supervisé permet d'automatiser cette détection.

Objectif du projet

À partir de données de vol réelles annotées par des événements de maintenance, détecter automatiquement les vols présentant des anomalies (comportements hors-norme) sans étiquettes préalables, et évaluer la capacité du modèle à anticiper les événements de maintenance.

Dataset

Nom	NGAFID Aviation Maintenance Dataset
Source	Rochester Institute of Technology / NGAFID
URL / Accès	arxiv.org/abs/2210.07317 Code Python de téléchargement fourni dans le paper
Détails	31 177h de données de vol réelles 28 935 vols annotés 2 111 événements de maintenance non planifiés 36 types de pannes Données réelles non simulées
Variables clés	Paramètres de vol multivariés par séquence temporelle (IAS, altitude, RPM, température huile, pression...) — labels : avant/après maintenance

Techniques ML attendues

- Réduction de dimensionnalité : PCA, t-SNE
- Détection d'anomalies non supervisée : Isolation Forest, LOF, One-Class SVM
- Agrégation de features par vol (statistiques sur séquence)
- Évaluation : précision détection avant maintenance

Déroutement recommandé

- Semaine 1 — Téléchargement dataset, exploration, agrégation par vol
- Semaine 2 — PCA/t-SNE, clustering exploratoire
- Semaine 3 — Isolation Forest, LOF, calibration du seuil
- Semaine 4 — Évaluation, rapport, présentation

Livrables attendus

- Pipeline détection d'anomalies + scoring par vol
- Visualisation t-SNE : vols normaux vs anormaux
- Rapport + présentation



Critères d'évaluation

Taux de détection avant maintenance | AUC-ROC | Visualisation t-SNE pertinente

Analyse NLP des rapports d'incidents de sécurité aérienne

NLP · Classification de texte · Clustering thématique

Techniques : NLP

Équipe : 3 étudiants | 3-4 semaines

Contexte et problématique

Les pilotes, contrôleurs et techniciens soumettent volontairement des milliers de rapports d'incidents à la NASA chaque année. Cette base de données textuelles constitue une mine d'informations sur les risques systémiques de l'aviation, encore largement inexploitée par l'IA.

Objectif du projet

Extraire automatiquement les causes récurrentes d'incidents à partir de rapports textuels désidentifiés, classifier les types d'incidents, et identifier des signaux faibles précurseurs d'accidents via le NLP.

Dataset

Nom	NASA ASRS — Aviation Safety Reporting System
Source	NASA
URL / Accès	asrs.arc.nasa.gov/search/database.html
Détails	Export CSV jusqu'à 10 000 rapports par téléchargement Narratives textuelles désidentifiées Métadonnées structurées (phase de vol, type aéronef, conditions météo, type d'anomalie) Accès libre sans inscription
Variables clés	Narratives Reporter 1 & 2, phase de vol, type d'aéronef, conditions, anomalie déclarée, synopsis — cible : catégorie d'incident (si supervisé) ou clusters (non supervisé)

Techniques ML attendues

- Prétraitement NLP : nettoyage, tokenisation, stopwords
- Vectorisation : TF-IDF, word embeddings (word2vec ou GloVe)
- Clustering non supervisé : K-Means, LDA (Latent Dirichlet Allocation)
- Classification supervisée si labels disponibles : Logistic Regression, SVM

Déroutement recommandé

- Semaine 1 — Téléchargement ASRS, nettoyage texte, EDA
- Semaine 2 — TF-IDF, LDA, détermination nombre de clusters
- Semaine 3 — Interprétation des clusters, classification supervisée
- Semaine 4 — Dashboard, rapport, présentation

Livrables attendus

- Pipeline NLP complet (prétraitement → vectorisation → clustering)
- Dashboard : nuage de mots par cluster + carte temporelle des incidents
- Rapport + présentation

Critères d'évaluation

Cohérence des clusters (silhouette score) | Interprétabilité thématique | Qualité du dashboard

Prédiction des débits fluviaux et risques de crue

Régression temporelle · LSTM léger · Contexte sahélien

Techniques : Régression temporelle

Équipe : 3 étudiants | 3-4 semaines

Contexte et problématique

Les crues soudaines au Sahel et en Afrique de l'Ouest causent chaque année des milliers de victimes et des pertes agricoles massives. Les systèmes d'alerte précoce actuels reposent sur des modèles hydrologiques complexes difficiles à déployer localement.

Objectif du projet

À partir de données météorologiques et hydrologiques historiques, construire un modèle de prédiction des débits fluviaux à horizon 24-72h pour alimenter un système d'alerte précoce aux crues, adapté au contexte des bassins versants sahéliens.

Dataset

Nom	Caravan — Global Community Dataset for Large-Sample Hydrology
Source	GitHub / Nature Scientific Data
URL / Accès	github.com/kratzert/Caravan huggingface.co/datasets/neuralhydrology/caravan
Détails	6 830 bassins versants mondiaux standardisés Données météo (précipitations, évapotranspiration, température) + débits journaliers historiques Bassins africains inclus Format NetCDF + CSV
Variables clés	Précipitations, ETP, température min/max, débit observé (cible), attributs du bassin (surface, pente, couverture végétale, type de sol)

Techniques ML attendues

- Sélection de bassins africains (Niger, Volta, Sénégal)
- Feature engineering : cumuls glissants, indices d'humidité
- Régression temporelle : Random Forest, XGBoost
- LSTM léger pour la partie séries temporelles
- Métriques hydrologiques : NSE, KGE, RMSE

Déroulement recommandé

- Semaine 1 — Sélection bassins africains, chargement, visualisation débits historiques
- Semaine 2 — Feature engineering, split temporel
- Semaine 3 — Modélisation, métriques hydrologiques
- Semaine 4 — Dashboard alerte, rapport, présentation

Livrables attendus

- Modèle de prédiction de débit à 24-72h
- Dashboard d'alerte : débit prédit vs seuils de crue par bassin
- Rapport + présentation

Critères d'évaluation

NSE (Nash-Sutcliffe Efficiency) > 0.6 | KGE | Dashboard fonctionnel avec seuils configurables

Prédiction de la potabilité de l'eau

Classification binaire · Application terrain · Santé publique

Techniques : Classification binaire

Équipe : 3 étudiants | 3-4 semaines

Contexte et problématique

En Afrique de l'Ouest, des millions de personnes n'ont pas accès à de l'eau potable sûre, faute de laboratoires d'analyse en zones rurales. Un outil de décision rapide basé sur quelques paramètres physico-chimiques mesurables sur le terrain pourrait sauver des vies.

Objectif du projet

À partir de paramètres physico-chimiques de l'eau (pH, turbidité, conductivité, dureté, nitrates, sulfates...), construire un classificateur binaire déterminant si une source d'eau est potable ou non, et déployer une application terrain simple d'utilisation.

Dataset

Nom	Water Potability Dataset
Source	Kaggle
URL / Accès	kaggle.com/datasets/adityakadiwal/water-potability
Détails	3 276 échantillons d'eau 9 paramètres physico-chimiques Label potable (1) / non potable (0) Valeurs manquantes à gérer CSV propre Téléchargement immédiat
Variables clés	pH, Hardness (dureté), Solids (solides dissous), Chloramines, Sulfate, Conductivity, Organic_carbon, Trihalomethanes, Turbidity — cible : Potability (0/1)

Techniques ML attendues

- Gestion des valeurs manquantes (imputation KNN ou médiane)
- Classification binaire : Logistic Regression, Random Forest, XGBoost, SVM
- Courbe ROC, seuil de décision optimisé (coût d'une erreur asymétrique)
- SHAP pour identifier les paramètres les plus critiques

Déroulement recommandé

- Semaine 1 — EDA, gestion valeurs manquantes, visualisation distributions
- Semaine 2 — Modélisation baseline, comparaison classifieurs
- Semaine 3 — Optimisation seuil, SHAP, validation croisée
- Semaine 4 — Application Streamlit, rapport, présentation

Livrables attendus

- Modèle de classification + calibration du seuil
- Application Streamlit : saisir les 9 paramètres → verdict potable/non potable + paramètres hors-norme en rouge
- Rapport + présentation

Critères d'évaluation

F1-score, AUC-ROC | Utilité terrain de l'application | Interprétabilité SHAP

Segmentation des ménages vulnérables pour ciblage humanitaire

Clustering · PCA · Visualisation géospatiale

Techniques : Clustering	Équipe : 3 étudiants 3-4 semaines
-------------------------	-------------------------------------

Contexte et problématique

Le ciblage des bénéficiaires des programmes d'aide humanitaire et sociale repose souvent sur des critères arbitraires ou incomplets. L'IA peut permettre d'identifier des profils de vulnérabilité objectifs et multidimensionnels à partir de données d'enquêtes ménages.

Objectif du projet

À partir de données d'enquêtes ménages (accès à l'eau, revenus, sécurité alimentaire, santé, éducation), identifier automatiquement des profils de vulnérabilité distincts et cartographier leur distribution géographique pour orienter les interventions.

Dataset

Nom	Enquêtes MICS UNICEF / DHS Burkina Faso & Afrique de l'Ouest
Source	UNICEF MICS / DHS Program
URL / Accès	mics.unicef.org/surveys dhsprogram.com/data/available-datasets.cfm
Détails	Données ménages Burkina Faso, Mali, Niger, Côte d'Ivoire Variables socio-économiques, santé, éducation, eau & assainissement Accès libre après inscription gratuite Format CSV/SPSS
Variables clés	Accès eau potable, revenus, sécurité alimentaire, niveau d'éducation, accès soins de santé, type de logement, équipements du ménage, variables géographiques — pas de cible (apprentissage non supervisé)

Techniques ML attendues

- Nettoyage et encodage de variables mixtes (numériques + catégorielles)
- Réduction de dimensionnalité : PCA, UMAP
- Clustering : K-Means, clustering hiérarchique, DBSCAN
- Profiling des clusters : description statistique de chaque groupe
- Cartographie : GeoPandas ou Folium

Déroutement recommandé

- Semaine 1 — Inscription MICS/DHS, téléchargement, exploration et nettoyage
- Semaine 2 — PCA, choix du nombre de clusters, K-Means
- Semaine 3 — Profiling clusters, cartographie géospatiale
- Semaine 4 — Rapport décisionnel, présentation

Livrables attendus

- Segmentation en 4-6 profils de vulnérabilité documentés
- Carte interactive des zones par profil de vulnérabilité

- Fiche descriptive de chaque cluster (pour décideurs non-techniques)
- Rapport + présentation

Critères d'évaluation

Score silhouette | Pertinence des profils (validation terrain) | Qualité carte interactive

Credit scoring en contexte africain

Classification · Déséquilibre de classes · Explicabilité réglementaire

Techniques : Classification

Équipe : 3 étudiants | 3-4 semaines

Contexte et problématique

En Afrique de l'Ouest, des millions de personnes restent exclues du crédit formel faute d'historique bancaire. Les institutions de microfinance ont besoin de modèles de scoring adaptés aux données disponibles dans ce contexte (comportementales, démographiques, géographiques).

Objectif du projet

Construire un modèle de scoring de crédit adapté au contexte africain, prédisant le risque de défaut de remboursement, et générer une scorecard explicable utilisable par les agents de crédit d'une IMF.

Dataset

Nom	African Credit Scoring Challenge
Source	Kaggle
URL / Accès	kaggle.com/datasets/ifeadewumi/african-credit-scoring-challenge
Détails	Dataset spécifiquement africain Variables comportementales, démographiques et géographiques Label défaut / non-défaut Déséquilibre de classes à gérer CSV propre
Variables clés	Données comportementales (historique de transactions, régularité des paiements), démographiques (âge, situation familiale, localisation), financières (revenus, montant demandé) — cible : défaut (0/1)

Techniques ML attendues

- Analyse du déséquilibre de classes + SMOTE
- Classification : Logistic Regression (baseline), Random Forest, XGBoost
- SHAP values pour l'explicabilité réglementaire
- Construction d'une scorecard (points par critère)
- Métriques : AUC-PR (plus pertinente qu'AUC-ROC sur classes déséquilibrées)

Déroulement recommandé

- Semaine 1 — EDA, analyse du déséquilibre, encodage
- Semaine 2 — Baseline + SMOTE + comparaison modèles
- Semaine 3 — SHAP, construction scorecard, calibration
- Semaine 4 — Dashboard, rapport, présentation

Livrables attendus

- Modèle de scoring + scorecard lisible par un agent de crédit
- Dashboard de décision de crédit : score par client + explication des facteurs
- Rapport + présentation

Critères d'évaluation

AUC-PR | Gini coefficient | Lisibilité de la scorecard | Utilité métier du dashboard

Détection de fraude financière

Classification · Déséquilibre extrême · Monitoring quasi-temps réel

Techniques : Classification	Équipe : 3 étudiants 3-4 semaines
-----------------------------	-------------------------------------

Contexte et problématique

Avec l'explosion du mobile money en Afrique de l'Ouest (Orange Money, Wave, MTN MoMo), la fraude financière devient un risque critique. Sur des millions de transactions, seule une infime fraction est frauduleuse — ce qui rend le problème statistiquement très difficile.

Objectif du projet

Construire un système de détection de fraude robuste sur un dataset fortement déséquilibré (0.17% de fraudes), en utilisant des métriques adaptées et en expliquant les décisions pour qu'elles soient actionnables par les équipes de contrôle.

Dataset

Nom	Credit Card Fraud Detection — ULB Machine Learning Group
Source	Kaggle
URL / Accès	kaggle.com/datasets/mlg-ulb/creditcardfraud
Détails	284 807 transactions 492 fraudes (0.17%) Features PCA anonymisées (V1-V28) + Montant + Temps Benchmark mondial de référence CSV propre Téléchargement immédiat
Variables clés	V1 à V28 (composantes PCA anonymisées), Amount (montant), Time (secondes depuis première transaction) — cible : Class (0=normal, 1=fraude)

Techniques ML attendues

- Analyse du déséquilibre extrême : SMOTE, ADASYN, class_weight
- Classification : Random Forest, XGBoost, Isolation Forest (anomalie)
- Métriques adaptées : F1, AUC-PR (precision-recall), pas accuracy
- Seuil de décision optimisé selon coût métier (faux positif vs faux négatif)
- SHAP pour expliquer les alertes fraude

Déroulement recommandé

- Semaine 1 — EDA, visualisation déséquilibre, baseline naïf
- Semaine 2 — SMOTE, Random Forest, XGBoost, comparaison
- Semaine 3 — Isolation Forest, optimisation seuil, SHAP
- Semaine 4 — Dashboard, rapport, présentation

Livrables attendus

- Modèle de détection + justification du seuil choisi
- Dashboard de monitoring : transactions suspectes en quasi-temps réel + analyse des faux positifs/négatifs
- Rapport + présentation

Critères d'évaluation

AUC-PR | F1-fraude | Justification du seuil | Qualité du dashboard de monitoring
