

INSTITUT INTERNATIONAL DE L'EAU ET DE L'ENVIRONNEMENT (2iE)



Informatique Intelligence Artificielle et
Application

Introduction au Machine Learning

Maintenance predictive équipements lourds miniers

Realise par :

YAMBOGO Brice

YAMEOGO Sylviane Laure Rolande

BIAM Kwami Alfred Jordal

Date : 31 mai 2026

Table des matières

1	Introduction	1
1.1	Enjeu operationnel	1
1.2	Objectifs M3	1
2	Donnees	1
2.1	Sources	2
2.2	Qualite et preparation des donnees	2
2.3	Analyse exploratoire	2
2.4	Variables	4
3	Methodologie	4
3.1	Architecture du projet	5
3.2	Preparation	5
3.3	Feature engineering temporel	5
3.4	Validation temporelle	6
3.5	Selection operationnelle des modeles	6
4	Modeles	6
4.1	Classification panne	6
4.2	Pretraitement commun	7
4.3	Regression RUL	7
4.4	Justification des metriques	7
5	Resultats	7
5.1	Classification	7
5.2	RUL	9
5.3	Etat operationnel de la flotte	9
5.4	Interpretabilite	10
6	Dashboard	10
6.1	Regles de decision	11
6.2	Design visuel	11
6.3	Utilite pour la soutenance	12
7	Discussion	13
7.1	Analyse critique des resultats	13
7.2	Recommandations metier	13
7.3	Ameliorations futures	14
8	Conclusion	14

1	Annexe : protocole de reproduction	14
2	Annexe : grille de correspondance M3	15

Résumé

Ce projet répond à la fiche M3 du cours d'Introduction au Machine Learning : construire un système de maintenance prédictive pour des équipements lourds miniers à partir de données capteurs industrielles. Le pipeline exploite le jeu Microsoft Azure Predictive Maintenance et le jeu AI4I 2020 comme référence complémentaire. Deux objectifs métiers sont traités : prédire une panne dans les 24 prochaines heures et estimer la durée de vie résiduelle, ou RUL, de chaque machine. La solution comprend un pipeline reproductible, des variables temporelles, plusieurs modèles supervisés, une validation temporelle stricte et un dashboard Streamlit de décision. Le dashboard classe les machines par priorité, affiche la probabilité de panne, la RUL estimée et recommande une action de maintenance.

1 Introduction

Les mines utilisent des équipements lourds tels que foreuses, camions-bennes, convoyeurs et concasseurs. Ces machines fonctionnent dans des conditions severes : poussiere, vibrations, forte charge mecanique et contraintes thermiques. Une panne non planifiee provoque une perte de production, des couts de reparation eleves, une mobilisation urgente des equipes et parfois un risque de securite.

La maintenance predictive consiste a exploiter les donnees capteurs pour anticiper les defaillances. Dans ce projet, l'objectif n'est pas seulement de construire un modele performant, mais de fournir un outil de decision utilisable par une equipe maintenance : quelles machines inspecter, avec quel niveau d'urgence, et pourquoi.

1.1 Enjeu operationnel

Dans une mine, une prediction n'a de valeur que si elle se transforme en action. Une probabilite brute de panne ne suffit pas : le chef d'atelier doit savoir si la machine peut continuer a produire, si une inspection est necessaire, ou si un arret controle est preferable. Le projet traduit donc les sorties du modele en trois niveaux : normal, surveillance et critique. Cette logique rapproche le travail machine learning d'un outil de pilotage industriel.

Le choix d'un horizon de 24 heures est coherent avec l'organisation d'une maintenance de site : il permet d'integrer l'alerte dans le planning journalier, de verifier la disponibilite des pieces et de mobiliser une equipe sans attendre la casse. La RUL complete cette alerte : deux machines peuvent avoir la meme probabilite de panne, mais celle qui a la RUL la plus faible doit etre traitee en premier.

1.2 Objectifs M3

Conformement a la fiche projet M3, les objectifs sont :

- explorer des series temporelles de capteurs industriels ;
- construire des variables temporelles : moyennes glissantes, ecart-types glissants, retards et differences ;
- predire une panne dans un horizon de 24 heures ;
- estimer la RUL des machines ;
- valider les modeles sur le futur, sans fuite de donnees ;
- deployer un dashboard de suivi par equipement avec probabilite de panne et RUL estimee.

2 Donnees

2.1 Sources

Deux sources sont utilisees :

- **Microsoft Azure Predictive Maintenance** : 100 machines, capteurs horaires, historiques d'erreurs, maintenances et pannes ;
- **AI4I 2020 Predictive Maintenance** : 10 000 observations, cinq types de pannes et variables physiques normalisees.

Le jeu Azure constitue la base principale car il contient la dimension temporelle necessaire a la prediction de panne et au calcul de la RUL. AI4I sert de reference complementaire pour enrichir le contexte de panne et conserver un mode de demonstration robuste lorsque les donnees externes ne sont pas disponibles.

2.2 Qualite et preparation des donnees

Les donnees Azure sont constituees de plusieurs tables. La telemetrie est horaire, tandis que les pannes, erreurs et maintenances sont des journaux evenementiels. Le premier enjeu est donc de reconstruire une table machine-temps unique. Les dates sont converties au meme format, les tables sont jointes par `machineID` et `datetime`, puis les evenements rares sont transformes en variables exploitables par les modeles.

Le projet evite de supprimer agressivement les lignes contenant des valeurs manquantes, car les absences sont frequentes dans les series temporelles industrielles. Les variables manquantes sont imputees dans un pipeline scikit-learn afin que la preparation appliquee a l'entrainement soit exactement la meme que celle appliquee au test et au dashboard.

2.3 Analyse exploratoire

L'analyse exploratoire confirme le principal enjeu statistique du projet : les pannes a horizon 24 heures sont rares par rapport au volume total de telemetrie. Cette rarete justifie l'utilisation de metriques orientees classe panne et l'optimisation du seuil de decision.




FIGURE 1 – Distribution de la cible binaire. La classe panne est minoritaire, ce qui rend l'accuracy insuffisante pour juger la qualite du modele.

L'étude des signaux capteurs montre aussi que les variables ne doivent pas être traitées comme des observations indépendantes. Les évolutions temporelles, les ruptures de régime et la variabilité récente sont essentielles pour détecter une dégradation.




FIGURE 2 – Exemple d'évolution temporelle des capteurs sur une machine. Les tendances et variations justifient les rolling features, les lags et les différences.

2.4 Variables

Les variables principales sont les mesures capteurs **volt**, **rotate**, **pression** et **vibration**. Elles sont complétées par le modèle de machine, l'âge, le compteur d'erreurs et les historiques de pannes. La cible de classification est :

$$y_{panne} = 1 \quad \text{si une panne survient dans les 24 prochaines heures.}$$

La cible de régression est la RUL :

$$RUL = t_{prochaine\ panne} - t_{observation}$$

exprimée en heures.

3 Methodologie

3.1 Architecture du projet

Le projet est organise en modules afin de separer les responsabilites :

- `src/data_loader.py` : chargement des donnees Azure et AI4I, generation de secours, snapshot machine ;
- `src/feature_engineering.py` : construction de la table de variables temporelles ;
- `src/models.py` : pretraitement, entraînement classification et regression ;
- `src/evaluation.py` : metriques, matrices de confusion et predictions ;
- `src/project_pipeline.py` : orchestration de bout en bout ;
- `dashboard/app.py` : restitution operationnelle Streamlit.

Cette structure rend le projet plus professionnel qu'un notebook unique : les notebooks peuvent expliquer les etapes, mais la logique reutilisable est centralisee dans `src/`. Les artefacts sont exportes dans `data/processed/` et `models/`, ce qui permet au dashboard de se lancer sans refaire l'entraînement.

3.2 Preparation

Le pipeline charge les tables brutes, harmonise les dates, joint la telemetrie avec les caracteristiques machines, ajoute les erreurs et calcule la prochaine panne connue pour chaque machine. Le projet inclut un generateur synthetique compatible avec la structure Azure afin de garantir une execution complete meme si les donnees Kaggle ne sont pas presentes.

3.3 Feature engineering temporel

Les variables suivantes sont construites pour chaque capteur :

- moyennes glissantes sur 3 h, 6 h et 24 h ;
- ecart-types glissants sur 3 h, 6 h et 24 h ;
- retards de 1 h, 2 h, 6 h et 24 h ;
- difference premiere ;
- z-score par machine pour comparer une machine a son propre comportement historique.

Un compteur cumulatif d'erreurs et le temps depuis la derniere panne sont aussi ajoutees. Ces variables permettent de capturer la degradation progressive et les changements brusques de comportement.

TABLE 1 – Exemples de variables construites

Famille	Exemple	Utilite
Rolling mean	<code>vibration_rolling_mean_24h</code>	Niveau moyen recent
Rolling std	<code>pressure_rolling_std_6h</code>	Instabilite du signal
Lag	<code>rotate_lag_24</code>	Memoire du comportement passe
Difference	<code>volt_diff_1</code>	Variation brusque
Compteur	<code>error_count_cumulative</code>	Accumulation d'incidents
Normalisation	<code>vibration_zscore</code>	Ecart au profil habituel machine

3.4 Validation temporelle

La validation suit une logique chronologique par machine : les premieres observations servent a l'entrainement et les dernieres au test. Ce choix est essentiel : un modele de maintenance predictive doit generaliser vers le futur, pas memoriser des informations posterieures.

La validation aleatoire a ete evitee volontairement. Dans un probleme temporel, melanger les lignes peut produire une evaluation trop optimiste : des observations tres proches dans le temps se retrouvent simultanement en entrainement et en test, ce qui facilite artificiellement la prediction. Le split temporel par machine donne une mesure plus honnete de la performance attendue en production.

3.5 Selection operationnelle des modeles

Apres evaluation, le pipeline selectionne automatiquement :

- le meilleur classifieur non trivial selon le F1 de la classe panne, puis le rappel et l'AUC-PR ;
- le meilleur regresseur selon la MAE RUL, en excluant la baseline dummy.

Cette selection est ensuite appliquee a toute la table operationnelle pour produire `fleet_predictions.c`

Ce point est important : le dashboard ne doit pas afficher uniquement les lignes du test, mais un etat complet de la flotte.

4 Modeles

4.1 Classification panne

Les modeles compares sont :

- `DummyClassifier`, baseline ;
- `LogisticRegression` avec ponderation des classes ;
- `RandomForestClassifier` ;

- XGBoost lorsque la dependance est activee.

Le desequilibre de classes est traite par `class_weight` et par SMOTE lorsque disponible. Le seuil de decision est optimise sur la courbe precision-rappel, car le cout d'un faux negatif est plus eleve que celui d'un faux positif.

4.2 Pretraitement commun

Les variables numeriques passent par une imputation mediane puis une normalisation standard. Les variables categorielles sont imputees puis encodees en one-hot. Ce pretraitement est encapsule dans un `Pipeline`, ce qui evite les fuites de donnees et garantit que le meme traitement est applique en entraînement, test et inference.

4.3 Regression RUL

Les modeles de RUL compares sont :

- `DummyRegressor`, baseline ;
- `RandomForestRegressor` ;
- `SVR` ;
- XGBoost lorsque la dependance est activee.

Les metriques utilisees sont MAE, RMSE, R^2 , score NASA asymetrique et MAE sur la zone critique.

4.4 Justification des metriques

Pour la classification, le rappel de la classe panne est prioritaire : une panne non detectee peut provoquer une immobilisation couteuse. La precision reste importante pour eviter de saturer l'equipe maintenance avec trop de fausses alertes. Le F1 panne donne un compromis entre ces deux objectifs.

Pour la RUL, la MAE est facile a interpreter en heures. La RMSE penalise davantage les grandes erreurs. Le score NASA est asymetrique : il penalise differemment les predictions trop optimistes et trop pessimistes, ce qui est pertinent pour les systemes pronostiques.

5 Resultats

5.1 Classification

Les metriques prioritaires sont le rappel panne, la precision panne, le F1 panne et l'AUC-PR. L'accuracy n'est pas privilegiee car la cible peut etre desequilibree. Dans l'execution actuelle, la regression logistique ponderee fournit le meilleur compromis operationnel : rappel panne de 1,00, F1 panne de 0,337 et AUC-PR de 0,418. La Random Forest presente une AUC-ROC elevee mais un rappel panne plus faible au seuil retenu.

TABLE 2 – Indicateurs suivis pour la classification

Indicateur	Role	Interpretation metier
Precision panne	Fiabilite des alertes	Part des alertes reellement proches d'une panne
Rappel panne	Couverture du risque	Part des pannes detectees avant l'evenement
F1 panne	Compromis	Equilibre precision/rappel sur la classe critique
AUC-PR	Robustesse	Qualite du classement en contexte desequilibre

TABLE 3 – Resultats de classification de l'execution courante

Modele	Precision panne	Rappel panne	F1 panne	AUC-PR
Dummy	0.000	0.000	0.000	0.017
Logistic Regression	0.203	1.000	0.337	0.418
Random Forest	0.203	0.093	0.128	0.219




FIGURE 3 – Comparaison visuelle des modeles de classification sur la classe panne. Le modele selectionne privilegie le rappel pour limiter les pannes manquees.

La precision de 0,203 signifie qu'une partie des alertes sont des faux positifs. Dans un contexte minier, ce resultat peut rester acceptable si les alertes declenchent d'abord une inspection courte, et non un arret systematique. Le rappel de 1,00 indique que les pannes presentes dans le jeu de test sont detectees par le modele selectionne.

5.2 RUL

La regression RUL est evaluee par erreur absolue moyenne. La zone critique, definie par une RUL faible, est suivie separement car elle correspond aux decisions urgentes : arret controle, inspection immediate ou planification sous 72 heures. Dans l'execution courante, la Random Forest RUL obtient la meilleure MAE globale, environ 198 heures, contre environ 415 heures pour la baseline.

TABLE 4 – Resultats de regression RUL de l'execution courante

Modele	MAE (h)	RMSE (h)	MAE zone critique (h)
Dummy	414.75	426.92	531.10
Random Forest RUL	197.70	233.52	216.84
SVR RUL	272.14	290.28	355.26




FIGURE 4 – Comparaison des erreurs de regression RUL. La Random Forest RUL ameliore nettement la baseline en MAE et RMSE.

La RUL reste la partie la plus difficile du projet. Une erreur de plusieurs jours peut etre trop elevee pour une automatisation directe. En revanche, combinee avec la probabilite de panne, elle reste utile pour classer les priorites et declencher une verification humaine.

5.3 Etat operationnel de la flotte

Apres correction de l'inference operationnelle, les predictions ne sont plus concentrees a 100%. La probabilite moyenne de panne sur l'ensemble des observations est d'environ 12,9%, avec une distribution etalee entre des machines normales et des machines en alerte.

Sur le dernier snapshot, 15 machines sont normales, 1 machine est en surveillance et 4 machines sont critiques. Cette repartition permet une priorisation claire.

5.4 Interpretabilite

Le projet integre une logique d'interpretabilite compatible SHAP ou importance de variables. Dans l'environnement actuel, SHAP est conserve comme extension optionnelle car son installation peut dependre de la version de Python. Pour fournir malgre tout une interpretation concrete et reproductible, le rapport exploite les importances du modele sauvegarde. Cette approche donne une lecture directe des variables qui contribuent le plus au signal d'alerte.




FIGURE 5 – Variables les plus influentes selon le modele de classification sauvegarde. Les variables temporelles et capteurs dominant l'explication du risque.

Cette figure remplit le meme role pedagogique qu'une premiere analyse SHAP globale : elle permet d'expliquer au jury que le modele ne se limite pas a une boite noire, mais s'appuie sur des signaux interpretable tels que la vibration, la pression, les lags et les statistiques glissantes. Dans le dashboard, les facteurs de vigilance par machine sont resumes a partir des deviations normalisees des capteurs et du compteur d'erreurs. Cette restitution rend le resultat plus acceptable pour un decisionnaire non specialiste.

6 Dashboard

Le dashboard Streamlit a ete concu comme un outil operationnel, pas comme une simple page de graphiques. Il adopte un style premium blanc/noir et se concentre sur

trois questions :

- quelles machines sont critiques maintenant ?
- quelle est la probabilité de panne et la RUL estimée ?
- quelle action de maintenance est recommandée ?

La page *Decision flotte* affiche les KPI principaux, la machine prioritaire, une file de décision triée par score de priorité et l'évolution du risque. La page *Diagnostic machine* donne le détail capteur, le risque, la RUL et les facteurs de vigilance d'un équipement. La page *Performance modeles* permet de justifier la qualité des modèles pendant la maintenance.

6.1 Regles de decision

Les seuils utilisés dans le dashboard sont :

- critique si probabilité de panne $\geq 65\%$ ou $RUL \leq 20$ heures ;
- surveillance si probabilité de panne $\geq 40\%$ ou $RUL \leq 72$ heures ;
- normal sinon.

Ces seuils peuvent être ajustés par le responsable maintenance selon le coût d'un arrêt, la disponibilité des pièces et la criticité de l'équipement. La version actuelle privilégie la détection précoce plutôt que la réduction maximale des fausses alertes.

6.2 Design visuel

Le style du dashboard a été retravaillé en blanc/noir premium. Le choix visuel est volontairement sobre : fond blanc, typographie noire, bordures fines, graphiques en niveaux de gris et sidebar noire. Cette direction évite les couleurs décoratives et met l'attention sur la décision. Les niveaux d'alerte restent lisibles par le texte, les KPI et le tri de priorité, même sans palette colorée.

Fleet Risk Control

Vue decision flotte - style dashboard blanc/noir




FIGURE 6 – Capture de la vue decision flotte. Elle met en avant les KPI, le niveau de risque et les machines prioritaires pour l'équipe maintenance.




FIGURE 7 – Capture de la vue diagnostic machine. Elle croise l'évolution de la probabilité de panne avec la RUL estimée pour faciliter la decision.

6.3 Utilite pour la soutenance

Le dashboard permet de presenter le projet comme un systeme complet :

- le jury voit immédiatement la flotte, les machines critiques et les recommandations ;
- une machine peut être sélectionnée pour expliquer les signaux capteurs ;
- les métriques modèles justifient les choix techniques ;
- les données et modèles sont chargés depuis les artefacts du pipeline, ce qui montre la reproductibilité.

7 Discussion

Le projet respecte les exigences M3 : séries temporelles, feature engineering, classification binaire, régression RUL, validation temporelle et dashboard. Les choix de conception sont orientés vers l'utilité industrielle. Le seuil de panne est ajustable et les alertes sont traduites en actions compréhensibles.

Les limites principales sont les suivantes :

- le nombre de pannes observées est limité par rapport au volume de télémétrie ;
- les données ne contiennent pas certaines variables métier : charge utile, température ambiante, qualité des pièces ou conditions de piste ;
- le prototype n'est pas connecté à un flux SCADA temps réel ;
- la RUL calculée dépend de la prochaine panne observée et ne représente pas tous les mécanismes physiques.

7.1 Analyse critique des résultats

Le rappel élevé du classifieur est un point fort pour une logique de prévention. Cependant, la précision montre qu'il faut éviter une automatisation aveugle. Le bon usage du modèle est un système d'aide à la décision : il signale les équipements à inspecter, puis l'expertise maintenance confirme l'action.

La performance RUL doit aussi être interprétée avec prudence. Une RUL précise à l'heure près est difficile avec les seules variables disponibles. Le modèle apporte surtout une priorisation relative : une machine avec une RUL très faible et une probabilité de panne élevée doit passer avant une machine dont les signaux sont normaux.

7.2 Recommandations métier

Pour utiliser ce type d'outil dans une mine, il est recommandé de :

- commencer par un pilote sur un sous-parc critique ;
- comparer les alertes aux rapports d'inspection réels ;
- ajuster les seuils selon les coûts de faux positifs et faux négatifs ;
- intégrer les retours des maintenanciers dans une boucle d'amélioration ;
- connecter progressivement le dashboard à une GMAO.

7.3 Améliorations futures

Les extensions techniques possibles sont :

- calibration probabiliste des scores ;
- modeles de survie pour la RUL ;
- validation par machine jamais vue, en plus de la validation temporelle ;
- integration de SHAP complet dans le dashboard ;
- ajout de donnees de charge, temperature ambiante et historique de pieces ;
- deploiement temps reel avec ingestion streaming.

8 Conclusion

Ce projet fournit une chaine complete de maintenance predictive pour equipements lourds miniers. Il transforme des donnees capteurs en informations actionnables : probabilite de panne, RUL estimee, priorite machine et recommandation de maintenance. Le pipeline est reproductible, les artefacts sont sauvegardes et le dashboard facilite les prises de decision.

Pour une suite industrielle, les ameliorations prioritaires seraient la calibration probabiliste, l'ajout de couts metier, le streaming temps reel et l'integration avec une GMAO.

1 Annexe : protocole de reproduction

1. Installer les dependances avec `python -m pip install -r requirements.txt`.
2. Executer `python run_pipeline.py`.
3. Verifier les artefacts dans `data/processed/` et `models/`.
4. Lancer le dashboard avec `python -m streamlit run dashboard/app.py`.
5. Compiler le rapport avec `pdflatex rapport/rapport_M3.tex`.

2 Annexe : grille de correspondance M3

TABLE 5 – Correspondance entre consignes M3 et livrables

Consigne M3	Implementation
Exploration capteurs	Notebooks EDA et table <code>feature_table.csv</code>
Rolling mean, lag features	<code>src/feature_engineering.py</code>
Classification panne/pas panne	<code>train_classifiers</code> et metriques panne
Regression RUL	<code>train_rul_models</code> et MAE RUL
Validation temporelle	<code>temporal_train_test_split</code> par machine
Dashboard par equipement	<code>dashboard/app.py</code> , page diagnostic machine
Probabilite panne et RUL	Colonnes <code>predicted_failure_probability</code> et <code>predicted_rul</code>
Rapport	<code>rapport/rapport_M3.tex</code> et PDF compile

Livrables

- Pipeline : `src/project_pipeline.py`
- Notebooks : `notebooks/01_EDA.ipynb` a `06_finalisation_projet.ipynb`
- Modeles sauvegardes : `models/*.joblib`
- Dashboard : `dashboard/app.py`
- Resultats : `data/processed/metrics_summary.json`, `fleet_predictions.csv`, `fleet_snapshot`

Bibliographie

- [1] A. K. S. Jardine, D. Lin, and D. Banjevic. A review on machinery diagnostics and prognostics implementing condition-based maintenance. *Mechanical Systems and Signal Processing*, 2006.
- [2] T. Chen and C. Guestrin. XGBoost : A scalable tree boosting system. *KDD*, 2016.
- [3] S. Lundberg and S.-I. Lee. A Unified Approach to Interpreting Model Predictions. *NeurIPS*, 2017.
- [4] S. Matzka. Explainable Artificial Intelligence for Predictive Maintenance Applications. *IEEE PHM*, 2021.
- [5] A. Geron. *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow*. O'Reilly, 2022.