

INSTITUT INTERNATIONAL DE L'EAU ET DE L'ENVIRONNEMENT (2iE)



Introduction au Machine Learning

Maintenance prédictive équipements lourds miniers

Réalisé par :

YAMBOGO Brice

BIAM Kwami Alfred Jordal

YAMEOGO Sylviane Laure Rolande

Date : 2 juin 2026

Table des matières

1	Introduction	1
1.1	Enjeu opérationnel	1
1.2	Objectifs M3	1
2	Données	2
2.1	Sources	2
2.2	Qualité et préparation des données	2
2.3	Analyse exploratoire	2
2.4	Variables	4
3	Méthodologie	4
3.1	Architecture du projet	5
3.2	Feature engineering temporel	5
3.3	Validation temporelle	5
3.4	Sélection opérationnelle des modèles	6
4	Modèles	6
4.1	Classification des défaillances	6
4.2	Régression pour l'estimation de la RUL	6
5	Résultats et Analyse des Figures	6
5.1	Analyse fine de la classification	6
5.2	Analyse de l'estimation de la RUL	9
5.3	Interprétabilité et Facteurs de Dégradation	9
6	Dashboard Streamlit	10
6.1	Logique d'alerte et Seuils décisionnels	10
7	Discussion et Perspectives	12
8	Conclusion	13
1	Annexe : Protocole de reproduction	13
2	Annexe : Grille d'adéquation aux exigences M3	13

Résumé

Ce projet répond à la fiche M3 du cours d'Introduction au Machine Learning : construire un système de maintenance prédictive pour des équipements lourds miniers à partir de données capteurs industrielles. Le pipeline exploite le jeu Microsoft Azure Predictive Maintenance et le jeu AI4I 2020 comme référence complémentaire. Deux objectifs métiers sont traités : prédire une panne dans les 24 prochaines heures et estimer la durée de vie résiduelle, ou RUL, de chaque machine. La solution comprend un pipeline reproductible, des variables temporelles, plusieurs modèles supervisés, une validation temporelle stricte et un dashboard Streamlit de décision. Le dashboard classe les machines par priorité, affiche la probabilité de panne, la RUL estimée et recommande une action de maintenance adaptée.

1 Introduction

Les mines utilisent des équipements lourds tels que foreuses, camions-bennes, convoyeurs et concasseurs. Ces machines fonctionnent dans des conditions sévères : poussière, vibrations, forte charge mécanique et contraintes thermiques élevées. Une panne non planifiée provoque une perte de production immédiate, des coûts de réparation élevés, une mobilisation d'urgence des équipes et parfois un risque de sécurité majeur.

La maintenance prédictive consiste à exploiter les données capteurs pour anticiper les défaillances avant qu'elles ne surviennent. Dans ce projet, l'objectif n'est pas seulement de construire un modèle algorithmique performant, mais de fournir un outil de décision directement utilisable par une équipe de maintenance sur site : quelles machines inspecter, avec quel niveau d'urgence, et pour quelles raisons techniques.

1.1 Enjeu opérationnel

Dans l'environnement d'une exploitation minière, une prédiction n'a de valeur que si elle se transforme en action concrète. Une probabilité brute de panne ne suffit pas : le chef d'atelier doit savoir si la machine peut continuer à produire, si une inspection sur site est nécessaire, ou si un arrêt contrôlé est préférable. Le projet traduit donc les sorties du modèle en trois niveaux opérationnels distincts : normal, surveillance et critique. Cette logique rapproche le travail de modélisation d'un véritable outil de pilotage industriel.

Le choix d'un horizon de prédiction de 24 heures est cohérent avec l'organisation de la maintenance sur site : il permet d'intégrer l'alerte dans le planning journalier, de vérifier la disponibilité des pièces de rechange et de mobiliser une équipe technique sans attendre la casse de l'équipement. La RUL (*Remaining Useful Life*) complète cette alerte : si deux machines présentent la même probabilité de panne, celle affichant la RUL la plus faible est traitée en priorité absolue.

1.2 Objectifs M3

Conformément à la fiche projet M3, les objectifs fixés sont :

- explorer des séries temporelles complexes issues de capteurs industriels ;
- construire des variables temporelles avancées : moyennes glissantes, écarts-types glissants, retards (*lags*) et différences premières ;
- prédire une panne dans un horizon de 24 heures (classification binaire) ;
- estimer la durée de vie résiduelle (RUL) des machines (régression) ;
- valider les modèles sur des fenêtres futures, sans aucune fuite de données ;
- déployer un dashboard Streamlit fonctionnel de suivi par équipement avec probabilité de panne et RUL estimée.

2 Données

2.1 Sources

Deux sources de données principales sont exploitées :

- **Microsoft Azure Predictive Maintenance** : Contient le suivi de 100 machines, des mesures de capteurs horaires, les historiques d'erreurs, les interventions de maintenance et les pannes réelles ;
- **AI4I 2020 Predictive Maintenance** : Comprend 10 000 observations, cinq types de pannes spécifiques et des variables physiques normalisées.

Le jeu Azure constitue la base principale de l'architecture car il intègre la dimension temporelle séquentielle indispensable à la prédiction à horizon fixe et au calcul de la RUL. Le jeu AI4I sert de référence complémentaire pour enrichir le contexte fonctionnel des pannes.

2.2 Qualité et préparation des données

Les données brutes d'Azure sont constituées de plusieurs tables distinctes. La télémétrie est collectée sur une base horaire, tandis que les pannes, les erreurs et les maintenances sont consignées dans des journaux événementiels asynchrones. Le premier enjeu réside dans la reconstruction d'une table unique indexée par machine et par horodatage (`machineID`, `datetime`).

Le projet intègre une stratégie robuste de gestion des données manquantes, fréquentes au sein des séries temporelles industrielles. Les variables manquantes ou asynchrones sont imputées de manière cohérente à l'intérieur d'un pipeline d'ingénierie afin de garantir que les traitements appliqués lors de la phase d'entraînement soient rigoureusement identiques à ceux appliqués lors des phases de test et d'inférence en temps réel sur le dashboard.

2.3 Analyse exploratoire

L'analyse exploratoire met en évidence le principal défi statistique du projet : le déséquilibre extrême des classes. Les événements de panne à horizon 24 heures représentent une proportion infime du volume total de la télémétrie collectée.




FIGURE 1 – Distribution de la cible binaire. La classe panne est fortement minoritaire, ce qui rend l'exactitude (*accuracy*) insuffisante pour évaluer la pertinence réelle du modèle.

L'étude dynamique des signaux montre également que les mesures brutes ne peuvent être traitées de manière isolée. Les tendances lourdes, les variations soudaines de régime et la volatilité à court terme constituent les signatures caractéristiques d'une dégradation matérielle imminente.




FIGURE 2 – Évolution temporelle des signaux capteurs sur une machine industrielle avant défaillance. Les dérives observées légitiment l'extraction de variables glissantes et de retards.

2.4 Variables

Les descripteurs principaux mesurent les grandeurs physiques suivantes : tension (**volt**), vitesse de rotation (**rotate**), pression (**pressure**) et vibration (**vibration**). Ils sont enrichis par le modèle d'équipement, l'âge de la machine, le cumul des erreurs et l'historique des pannes. La cible de classification est définie mathématiquement par :

$$y_{\text{panne}} = 1 \quad \text{si une panne survient dans l'intervalle } [t, t + 24 \text{ heures}], \quad 0 \text{ sinon.}$$

La cible de régression modélisant la RUL est exprimée en heures :

$$\text{RUL} = t_{\text{prochaine panne}} - t_{\text{observation}}$$

3 Méthodologie

3.1 Architecture du projet

Le code source est structuré en modules indépendants afin de garantir une séparation stricte des responsabilités et une maintenabilité industrielle :

- `src/data_loader.py` : Chargement des tables Azure et AI4I, nettoyage et réalignement temporel ;
- `src/feature_engineering.py` : Calcul des variables glissantes, des retards et des indicateurs statistiques ;
- `src/models.py` : Encapsulation des pipelines de prétraitement, d'entraînement et d'optimisation hyperparamétrique ;
- `src/evaluation.py` : Calcul des métriques métier, matrices de confusion et courbes d'évaluation ;
- `src/project_pipeline.py` : Orchestration globale de la chaîne d'exécution ;
- `dashboard/app.py` : Interface utilisateur opérationnelle développée sous Streamlit.

Les artefacts sérialisés (modèles, transformateurs, résumés de métriques) sont exportés dans les répertoires `models/` et `data/processed/`, ce qui permet au dashboard de s'exécuter instantanément par simple chargement des fichiers d'inférence.

3.2 Feature engineering temporel

Pour extraire la dynamique des pannes, les transformations suivantes sont opérées pour chaque capteur :

- Moyennes glissantes sur des fenêtres de 3 h, 6 h et 24 h ;
- Écarts-types glissants sur des fenêtres de 3 h, 6 h et 24 h ;
- Variables de retard (*lags*) à $t - 1$ h, $t - 2$ h, $t - 6$ h et $t - 24$ h ;
- Différences premières pour mesurer l'accélération des dérives ;
- Normalisation locale par machine (*z-score* glissant).

TABLE 1 – Exemples de variables temporelles construites au sein du pipeline

Famille	Variable exemple	Utilité opérationnelle
Rolling mean	<code>vibration_rolling_mean_24h</code>	Détection des dérives de fond
Rolling std	<code>pressure_rolling_std_6h</code>	Mesure de l'instabilité du système
Lag	<code>rotate_lag_24</code>	Capture des cycles de fonctionnement passés
Difference	<code>volt_diff_1</code>	Identification des chocs électriques soudains
Compteur	<code>error_count_cumulative</code>	Quantification de la fatigue accumulée

3.3 Validation temporelle

Le fractionnement des données (*split*) respecte strictement la chronologie des observations pour chaque machine : les données les plus anciennes forment l'ensemble d'en-

traînement et les données les plus récentes constituent l'ensemble de test. Une validation croisée aléatoire traditionnelle induirait une surévaluation majeure des performances (fuite de données par proximité temporelle immédiate).

3.4 Sélection opérationnelle des modèles

Le pipeline évalue plusieurs familles d'algorithmes et sélectionne automatiquement le meilleur estimateur sur la base des critères suivants :

- **Classification** : Maximisation du score F1 réindexé sur la classe critique (panne), puis arbitrage par le Rappel et l'Aire Sous la Courbe Précision-Rappel (AUC-PR) ;
- **Régression** : Minimisation de l'Erreur Absolue Moyenne (MAE) de la RUL, avec exclusion systématique des modèles triviaux basés sur la moyenne.

4 Modèles

4.1 Classification des défaillances

Les performances de trois architectures ont été comparées : la Régression Logistique avec pondération inverse des classes (`class_weight='balanced'`), une Forêt Aléatoire de classification (`RandomForestClassifier`) et un modèle de boosting de gradient (`XGBoost`).

Pour compenser le déséquilibre massif, le seuil de décision probabiliste a fait l'objet d'une optimisation fine sur la courbe Précision-Rappel. L'objectif métier consiste à maximiser le rappel (détecter toutes les pannes) tout en maintenant un niveau de précision acceptable pour éviter la saturation des équipes de maintenance par de fausses alertes.

4.2 Régression pour l'estimation de la RUL

Pour l'évaluation continue de la durée de vie résiduelle, les modèles de régression testés intègrent un estimateur de référence linéaire, un modèle de vecteurs de support (SVR) et une Forêt Aléatoire de régression. Les performances sont mesurées à l'aide de la MAE globale ainsi que d'une MAE ciblée sur la zone critique ($RUL \leq 72$ heures).

5 Résultats et Analyse des Figures

5.1 Analyse fine de la classification

L'analyse de la classification repose sur l'évaluation objective de la capacité de prédiction à court terme (horizon 24 heures).




FIGURE 3 – Courbes Précision-Rappel (Precision-Recall Curves) des modèles évalués. La courbe met en évidence le compromis optimal trouvé pour stabiliser la détection malgré l'extrême déséquilibre.

Comme l'illustre la courbe Précision-Rappel (Figure 4.1), le modèle **XGBoost** affiche une aire sous la courbe supérieure ($AUC-PR = 0,39$), démontrant une meilleure capacité à maintenir un niveau de précision viable à des seuils de rappel intermédiaires. En revanche, la **Régression Logistique** pondérée se détache lorsque la priorité opérationnelle absolue est fixée sur la capture totale des pannes.




FIGURE 4 – Matrice de confusion du classifieur sélectionné sur l'ensemble de test. Elle permet de quantifier directement le taux de vrais positifs face aux fausses alertes.

La matrice de confusion (Figure 4.2) confirme cette orientation stratégique. Sur la totalité des pannes réelles présentes dans le jeu de test, aucune n'échappe au modèle (0 faux négatif), assurant une sécurité totale de l'outil de production. Les faux positifs générés représentent des alertes anticipées où le signal capteur s'est dégradé sans provoquer de rupture mécanique instantanée dans la fenêtre horaire définie, une caractéristique tolérable au sein d'une gestion de flotte minière.




FIGURE 5 – Comparaison globale des métriques de classification. Le graphique illustre le comportement protecteur de la Régression Logistique face aux autres estimateurs.

Le graphique comparatif des performances (Figure 4.3) synthétise cette hiérarchie. Alors que le **Random Forest** souffre d'un rappel excessivement bas (0,09) dû au déséquilibre structurel non corrigé, la **Régression Logistique (Pondérée)** équilibre le système en atteignant un score F1 stable de 0,337.

5.2 Analyse de l'estimation de la RUL

L'estimation continue de la durée de vie résiduelle permet de planifier finement les interventions sur le moyen terme.




FIGURE 6 – Graphique de performance de la régression de la RUL. Comparaison des erreurs absolues moyennes face à la ligne de base (Dummy Regressor).

La Figure 4.4 confronte les erreurs absolues moyennes (MAE) des différentes architectures de régression. Le modèle **Random Forest** RUL surpasse largement ses concurrents directs avec une MAE ramenée à 197,70 heures, contre 272,14 heures pour le modèle **SVR**. Il offre un gain décisionnel net de plus de 216 heures par rapport à un modèle naïf (**Dummy Regressor**), matérialisant la pertinence des descripteurs glissants calculés.

5.3 Interprétabilité et Facteurs de Dégradation

La transparence algorithmique est une condition sine qua non à l'adoption de la solution par les ingénieurs de terrain.




FIGURE 7 – Importance des variables du modèle de classification. Le graphique identifie les indicateurs physiques qui influencent le plus l’attribution d’un niveau de risque.

La Figure 4.5 met en exergue le poids prédominant des indicateurs statistiques glissants. Les variables `vibration_rolling_mean_24h` et `vibration_rolling_std_24h` se positionnent comme les principaux précurseurs de défaillance. Ce résultat est cohérent avec la physique des équipements miniers, où une hausse de la variance des vibrations traduit directement un jeu mécanique anormal, un désalignement d’arbre ou une usure avancée des roulements. Le cumul des erreurs passées (`error_count`) intervient également comme un facteur d’accélération de la fatigue machine.

6 Dashboard Streamlit

Le dashboard applicatif a été conçu selon une charte épurée axée sur l’aide à la décision technique rapide. Il s’articule autour de trois modules majeurs : la situation globale de la flotte, le diagnostic individuel approfondi par machine, et l’affichage transparent des métriques de validation pour le management.

6.1 Logique d’alerte et Seuils décisionnels

L’interface catégorise les équipements en fonction des règles suivantes :

- **Critique** : Probabilité de panne $\geq 65\%$ OU $RUL \leq 20$ heures $\rightarrow$ Arrêt immédiat ;
- **Surveillance** : Probabilité de panne $\geq 40\%$ OU $RUL \leq 72$ heures $\rightarrow$ Inspection programmée ;
- **Normal** : En dehors de ces plages $\rightarrow$ Poursuite des opérations.

Fleet Risk Control

Vue decision flotte - style dashboard blanc/noir




FIGURE 8 – Capture d'écran de la vue flotte du Dashboard. L'écran fournit une vision macroscopique instantanée de l'état de santé de l'ensemble du parc minier.

La vue d'ensemble de la flotte (Figure 5.1) met à disposition des gestionnaires des indicateurs clés de performance (*KPIs*) centralisés : le nombre total d'unités opérationnelles, le décompte exact des machines sous surveillance, ainsi que la liste priorisée des équipements en état critique. Cette approche permet de dimensionner instantanément les équipes d'intervention en début de quart.




FIGURE 9 – Capture d’écran de l’interface de diagnostic individuel. Cet écran présente l’historique temporel des capteurs et les prédictions associées à une unité sélectionnée.

L’écran de diagnostic approfondi (Figure 5.2) permet à un ingénieur de maintenance de cibler une machine spécifique. Il affiche en temps réel les probabilités de pannes calculées par le pipeline, la valeur exacte de la RUL estimée en heures, et trace l’historique récent des signaux capteurs (vibrations, pression, température) afin de valider visuellement la présence d’une dérive physique avant la confirmation de l’ordre de travail.

7 Discussion et Perspectives

Le projet remplit l’ensemble des exigences de la spécification M3. Toutefois, l’implémentation industrielle de ce prototype soulève des points d’attention critiques. Le déséquilibre intrinsèque des pannes limite la précision absolue du classifieur. De plus, l’absence de données contextuelles majeures (charge utile portée, température environnementale extérieure, historique de maintenance des pièces remplacées) contraint la capacité du modèle à anticiper certains modes de rupture purement mécaniques.

Pour une intégration sur site minier, il est recommandé de mettre en place une phase pilote sur un sous-parc de machines, d’ajuster dynamiquement les seuils de décision en intégrant les coûts financiers d’un faux positif face à un bris mécanique, et d’interfacer le pipeline directement avec le logiciel de GMAO (*Gestion de la Maintenance Assistée par Ordinateur*) du site.

8 Conclusion

Cette solution logicielle délivre une infrastructure reproductible complète de maintenance prédictive. En convertissant des signaux physiques de télémétrie en indicateurs clairs (niveaux de risque, heures de fonctionnement estimées avant défaillance), elle fournit une brique essentielle à l'optimisation de la disponibilité opérationnelle des équipements lourds miniers.

1 Annexe : Protocole de reproduction

1. Installation de l'environnement virtuel et des dépendances :

```
python -m pip install -r requirements.txt
```
2. Exécution séquentielle de la préparation et de la modélisation :

```
python run_pipeline.py
```
3. Lancement de l'interface graphique Streamlit :

```
python -m streamlit run dashboard/app.py
```
4. Compilation du présent rapport de synthèse :

```
pdflatex rapport/rapport_M3.tex
```

2 Annexe : Grille d'adéquation aux exigences M3

TABLE 2 – Matrice de traçabilité des livrables du projet

Exigence Fiche M3	Composant technique d'implémentation
Analyse descriptive des capteurs	Scripts EDA et table <code>feature_table.csv</code>
Calcul d'indicateurs glissants et retards	Module <code>src/feature_engineering.py</code>
Modélisation de la classification binaire	Algorithme de classification et optimisation du seuil
Estimation de la RUL continue	Architecture <code>RandomForestRegressor</code> dédiée
Validation sans distorsion du futur	Séparation temporelle stricte par identifiant machine
Restitution applicative décisionnelle	Dashboard interactif synoptique <code>dashboard/app.py</code>

Bibliographie

- [1] A. K. S. Jardine, D. Lin, and D. Banjevic. A review on machinery diagnostics and prognostics implementing condition-based maintenance. *Mechanical Systems and Signal Processing*, 2006.
- [2] T. Chen and C. Guestrin. XGBoost : A scalable tree boosting system. *KDD*, 2016.
- [3] S. Lundberg and S.-I. Lee. A Unified Approach to Interpreting Model Predictions. *Nordic Journal of Computing*, 2017.
- [4] S. Matzka. Explainable Artificial Intelligence for Predictive Maintenance Applications. *IEEE PHM*, 2021.