

INSTITUT INTERNATIONAL DE L'EAU ET DE L'ENVIRONNEMENT (2iE)



Maintenance Prédicative des Équipements Lourds Miniers

Projet M3 – Introduction au Machine Learning

Réalisé par :

YAMBOGO Brice · YAMEOGO Sylviane Laure Rolande · BIAM Kwami Alfred Jordal

Informatique Intelligence Artificielle et Application

2 juin 2026

- 1 Introduction
- 2 Données
- 3 Méthodologie
- 4 Modèles
- 5 Résultats
- 6 Dashboard
- 7 Discussion
- 8 Conclusion

Introduction

Problématique industrielle

Les mines utilisent des équipements lourds (foreuses, camions-bennes, convoyeurs, concasseurs) dans des conditions sévères :

- Poussière, vibrations, forte charge mécanique
- Contraintes thermiques élevées

Coût d'une panne non planifiée

- Perte de production immédiate
- Réparation urgente et coûteuse
- Mobilisation d'urgence des équipes
- Risques de sécurité potentiels

Solution : Maintenance Prédictive

Exploiter les données capteurs pour **anticiper les défaillances**.

Objectif du projet

Fournir un **outil de décision** utilisable par l'équipe maintenance :

- Quelles machines inspecter ?
- Avec quel niveau d'urgence ?
- Pourquoi ?

Tâches demandées

- 1 Explorer les séries temporelles capteurs
- 2 Construire des variables temporelles : moyennes glissantes, écarts-types, retards, différences
- 3 Prédire une panne dans les **24 prochaines heures**
- 4 Estimer la **RUL** (Remaining Useful Life)
- 5 Validation temporelle sans fuite de données
- 6 Déployer un dashboard opérationnel

Logique décisionnelle adoptée

L'horizon 24 h est cohérent avec le planning journalier mine. La RUL complète la probabilité de panne :

CRITIQUE	$P \geq 65\%$ ou $RUL \leq 20$ h
SURVEIL.	$P \geq 40\%$ ou $RUL \leq 72$ h
NORMAL	Sinon

Deux machines avec la même probabilité : celle à RUL plus faible est traitée en premier.

Données


Source principale : Azure PM

- 100 machines, capteurs horaires
- Tables : télémétrie, erreurs, maintenances, pannes
- Dimension temporelle complète

Source complémentaire : A14I 2020

- 10 000 observations
- 5 types de pannes
- Variables physiques normalisées
- Mode démonstration hors ligne

Défi principal : déséquilibre de classes



Les pannes sont rares $\Rightarrow$ l'accuracy n'est pas une bonne métrique.

Pipeline de préparation

- 1 Conversion et harmonisation des dates
- 2 Jointure par machineID et datetime
- 3 Transformation des événements rares en variables
- 4 Imputation dans un pipeline scikit-learn
- 5 Calcul de la prochaine panne (cible RUL)

Cibles

Classification :

$$y_{\text{panne}} = 1 \text{ si panne dans les 24 h}$$

Régression :

$$\text{RUL} = t_{\text{prochaine panne}} - t_{\text{obs}}$$

Variables capteurs

Mesures brutes : volt, rotate, pressure, vibration

Feature Engineering temporel

Famille	Fenêtre
Rolling mean	3h, 6h, 24h
Rolling std	3h, 6h, 24h
Lag	1h, 2h, 6h, 24h
Différence	1 ^{er} ordre
Z-score	par machine
Compteurs	cumul erreurs

Méthodologie

Structure des modules

- `src/data_loader.py` – chargement, génération de secours
- `src/feature_engineering.py` – variables temporelles
- `src/models.py` – prétraitement, entraînement
- `src/evaluation.py` – métriques et prédictions
- `src/project_pipeline.py` – orchestration bout en bout
- `dashboard/app.py` – restitution Streamlit

Reproductibilité

Les artefacts sont exportés dans `data/processed/` et `models/`. Le dashboard se lance sans refaire l'entraînement.

Prétraitement commun (Pipeline)

- Variables numériques : imputation médiane + normalisation standard
- Variables catégorielles : imputation + one-hot
- Même traitement entraînement / test / inférence
- Aucune fuite de données possible

Validation temporelle

Split chronologique par machine. Les premières observations → train ; les dernières → test.

La validation aléatoire est évitée : elle produirait une évaluation trop optimiste.

Modèles

Modèles comparés

- DummyClassifier (baseline)
- LogisticRegression avec class_weight
- RandomForestClassifier
- ExtraTreesClassifier

Traitement du déséquilibre

- class_weight sur les modèles
- Optimisation du seuil de décision
- Validation temporelle stratifiée

Métriques prioritaires

Métrique	Rôle
Rappel panne	Couverture du risque
Précision panne	Fiabilité des alertes
F1 panne	Compromis
AUC-PR	Robustesse déséquilibre

L'accuracy n'est pas retenue car la cible est déséquilibrée.

Justification

Une panne non détectée = arrêt coûteux. Le rappel est donc prioritaire sur la précision.

Modèles comparés

- DummyRegressor (baseline)
- RandomForestRegressor
- ExtraTreesRegressor

Métriques RUL

- MAE (interprétable en heures)
- RMSE (pénalise les grandes erreurs)
- R^2 (pouvoir explicatif)
- Score NASA asymétrique
- MAE zone critique (RUL faible)

Score NASA

Asymétrique : pénalise différemment les prédictions trop optimistes et trop pessimistes.

Pertinent pour les systèmes pronostiques industriels.

Zone critique

La MAE sur RUL faible est suivie séparément : elle correspond aux décisions urgentes (arrêt contrôlé, inspection immédiate, planification ≤ 72 h).


Résultats

Modèle	Préc.	Rappel	F1	AUC-PR
Dummy	0.000	0.000	0.000	0.017
Log. Regression	0.248	0.867	0.385	0.471
Random Forest	0.377	0.953	0.541	0.414

Modèle retenu

Random Forest

- Rappel = 0,953
- F1 = 0,541
- AUC-PR = 0,414




Précision 0,377 : les alertes déclenchent d'abord une inspection – pas un arrêt systématique.

Modèle	MAE (h)	RMSE (h)	MAE crit.
Dummy	415.92	428.06	532.27
Random Forest	129.10	149.39	172.34
Extra Trees	120.83	140.51	187.67

Modèle retenu


Extra Trees RUL

- MAE 121 h vs 416 h
- –71% d'erreur
- Meilleure RMSE globale



Combinée à la probabilité de panne, la RUL permet une priorisation relative des interventions.

Snapshot courant – 20 machines




Indicateurs clés

- P(panne) moyenne : **10,9%**
- Distribution étalée
- Plus de valeurs bloquées à 0 ou 100%

Décision immédiate

Concentrer les ressources sur les **4 machines en surveillance**. Les 16 normales peuvent continuer en production.

CRITIQUE 0 SURVEIL. 4 NORMAL 16



Approche

- Importances du modèle sauvegardé
- Extension SHAP optionnelle
- Variables temporelles et capteurs dominantes

Signaux clés

Vibration, pression, lags, rolling stats : signaux physiquement interprétables, pas une boîte noire.


Dans le dashboard

Facteurs de vigilance via déviations normalisées et compteur d'erreurs par machine.

Dashboard

Fleet Risk Control

Vue decision flotte - style dashboard blanc/noir




Page Décision Flotte

- KPI principaux en en-tête
- Machine prioritaire du moment
- File de décision triée par priorité
- Évolution temporelle du risque

Design visuel

Style premium blanc/noir : fond blanc, typographie noire, bordures fines, graphiques en niveaux de gris. Le choix sobre met l'attention sur la décision.



Page Diagnostic Machine

- Probabilité de panne et tendance
- RUL estimée
- Signaux capteurs détaillés
- Facteurs de vigilance

Valeur pour la soutenance

- Jury voit la flotte et les critiques
- Sélection machine pour les signaux
- Page performance : justifier les choix
- Artefacts chargés depuis le pipeline

Discussion

Points forts

- Pipeline reproductible et modulaire
- Rappel élevé : pannes détectées avant l'événement
- Validation temporelle honnête
- Dashboard actionnable (pas juste des graphiques)
- RUL améliore la baseline de 71%

Limites

- Peu de pannes dans le jeu de données
- Pas de variables : charge, T° ambiante, pièces
- Non connecté à un flux SCADA temps réel
- RUL dépend de la prochaine panne observée

Recommandations métier

- 1 Pilote sur un sous-parc critique
- 2 Comparer alertes vs rapports d'inspection réels
- 3 Ajuster seuils selon coûts FP/FN
- 4 Boucle d'amélioration avec les maintenanciers
- 5 Intégration progressive avec la GMAO

Bon usage du modèle

Le modèle est un **aide à la décision** : il signale les équipements à inspecter ; l'expertise maintenance confirme l'action. Pas d'automatisation aveugle.

Extensions techniques

- Calibration probabiliste des scores
- Modèles de survie pour la RUL
- Validation par machine jamais vue
- Intégration SHAP complète dans le dashboard
- Déploiement temps réel avec ingestion streaming

Enrichissement des données

- Données de charge utile
- Température ambiante
- Historique des pièces de rechange
- Connexion SCADA en temps réel

Priorités pour une suite industrielle

Calibration probabiliste, intégration des coûts métier, streaming temps réel, connexion GMAO.

Conclusion

Ce que le projet fournit

- Chaîne complète : données → dashboard
- Probabilité de panne par machine
- RUL estimée (h)
- Priorité et recommandation de maintenance
- Pipeline reproductible, artefacts sauvegardés

Conformité M3

Séries temporelles ✓ Feature engineering ✓
Classification ✓ Régression RUL ✓
Validation temporelle ✓ Dashboard ✓

Impact opérationnel

Le projet transforme des données capteurs brutes en informations actionnables. L'équipe maintenance sait **quoi faire, sur quelle machine, et pourquoi.**

Merci de votre attention

Questions ?

Consigne M3	Implémentation
Exploration capteurs	Notebooks EDA + feature_table.csv
Rolling mean, lag features	src/feature_engineering.py
Classification panne/pas panne	train_classifiers + métriques panne
Régression RUL	train_rul_models + MAE RUL
Validation temporelle	temporal_train_test_split par machine
Dashboard par équipement	dashboard/app.py, page diagnostic machine
Probabilité panne et RUL	Colonnes predicted_failure_probability et predicted_rul
Rapport	rapport/rapport_M3.tex et PDF compilé

Étapes

- ❶ Installer les dépendances :
`python -m pip install -r requirements.txt`
- ❷ Exécuter le pipeline :
`python run_pipeline.py`
- ❸ Vérifier les artefacts dans `data/processed/` et `models/`
- ❹ Lancer le dashboard :
`python -m streamlit run dashboard/app.py`
- ❺ Compiler le rapport :
`pdflatex rapport/rapport_M3.tex`

Livrables

`src/project_pipeline.py` `notebooks/01_EDA.ipynb` à `06_*.ipynb` `models/*.joblib` `dashboard/app.py`
`data/processed/metrics_summary.json`



A. K. S. Jardine, D. Lin, D. Banjevic. A review on machinery diagnostics and prognostics implementing condition-based maintenance. *Mech. Systems & Signal Processing*, 2006.



T. Chen, C. Guestrin. XGBoost : A scalable tree boosting system. *KDD*, 2016.



S. Lundberg, S.-I. Lee. A Unified Approach to Interpreting Model Predictions. *NeurIPS*, 2017.



S. Matzka. Explainable Artificial Intelligence for Predictive Maintenance Applications. *IEEE PHM*, 2021.



A. Géron. *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow*. O'Reilly, 2022.